Susana NOGUEIRA COSTA, Eurydice SEMASSOU & Sabirath SOUMANOU

Prévoir la consommation électrique du lendemain

Introduction

Nous proposons de remplacer la méthode actuelle « demain = aujourd'hui » par un modèle de prévision de la consommation électrique du lendemain. Sur des données jamais vues (233 jours), le modèle retenu (Random Forest) réduit l'erreur moyenne de 13,1 % par rapport à cette méthode (4,19 kWh contre 4,82 kWh par jour), mais pas par rapport à une simple moyenne des 7 derniers jours (4,18 kWh). Sous nos hypothèses, le gain est estimé à 127 600 € par an pour 10 000 foyers, mais il tombe à environ 21 600 € face à la moyenne 7 jours : nous recommandons un pilote de 3 mois avant tout déploiement.

Axe 1 · Cadrage métier

Élément	Réponse
Contexte	Un fournisseur d'électricité fictif achète à l'avance l'énergie qu'il revend à ses clients. Utilisateur du résultat : le responsable de l'approvisionnement.
Problème	Le fournisseur n'a pas de prévision fiable de la consommation du lendemain. S'il achète trop, le surplus est revendu moins cher ; s'il n'achète pas assez, il rachète en urgence à un prix plus élevé.
Décision	Chaque jour avant 10 h, fixer la quantité d'énergie à acheter pour le lendemain (horizon J+1).
Situation actuelle	Sans modèle : « demain sera comme aujourd'hui ». C'est notre référence.
Critère de succès	Réduire d'au moins 20 % l'erreur moyenne (MAE) par rapport à cette référence, sur la période de test. Résultat obtenu : 13,1 %.
Contraintes	Seules les informations connues à la fin du jour précédent sont utilisées ; découpage chronologique ; un seul foyer dans les données (décembre 2006 – novembre 2010).

Axe 2 · Type de problématique

La cible est `Consommation_kWh` : la consommation totale du foyer sur une journée, obtenue en additionnant sur 1 440 minutes la puissance active (kW) divisée par 60. Elle est connue pour tout l'historique et continue (de 4,2 à 79,6 kWh/jour). Le problème est donc **supervisé**, de type **régression**, et comme les observations sont ordonnées dans le temps, c'est de la **prévision** : découpage chronologique, variables de retard, validation temporelle.

Les autres types sont écartés : une **classification** perdrait l'information chiffrée dont l'acheteur d'énergie a besoin ; un **clustering** ignorerait la cible que nous connaissons ; une régression avec **découpage aléatoire** mélangerait le passé et le futur.

Susana NOGUEIRA COSTA, Eurydice SEMASSOU & Sabirath SOUMANOU

Axe 3 · Analyse et préparation des données

Description

Source : UCI Machine Learning Repository, *Individual Household Electric Power Consumption* (id 235), https://archive.ics.uci.edu/dataset/235/individual+household+electric+power+consumption, consulté le 18/10/2026 (licence à citer dans le README). Un seul foyer à Sceaux (France), une mesure par minute du 16/12/2006 au 26/11/2010 : 2 075 259 lignes, 10 colonnes.

Variable	Unité	Signification
`Date`, `Time`	jj/mm/aaaa, hh:mm:ss	Horodatage (1 ligne = 1 minute)
`Global_active_power`	kW	Puissance active moyenne : sert à calculer la cible
`Global_reactive_power`	kW	Puissance réactive moyenne
`Voltage`	V	Tension moyenne
`Global_intensity`	A	Intensité moyenne
`Sub_metering_1` / `_2` / `_3`	Wh	Cuisine / buanderie / chauffe-eau et climatisation

Qualité

25 979 lignes (1,25 %) ont des valeurs manquantes, toutes les mesures manquant en même temps : cela ressemble à une coupure du capteur. Elles touchent 82 journées, dont 9 entièrement vides. Sur 1 442 journées, nous gardons les **1 358 journées complètes** (1 440 mesures valides) et écartons les 84 autres : une somme sur une journée incomplète sous-estimerait la consommation, et nous n'imputons pas de moyenne pour ne pas inventer de consommations. Les journées écartées créent 67 trous dans le calendrier ; les retards sont donc construits **par date** (J-1, J-7), et une ligne dont le jour de référence est absent est retirée. Il reste **1 205 journées** exploitables.

[Insérer ici : série journalière, distribution, consommation par jour de la semaine, consommation par mois]

Cible et relations

- **Distribution.** Moyenne 26,0 kWh/jour (écart-type 9,9 ; médiane 25,6), peu asymétrique (skewness 0,55). Les jours les plus faibles (4,2 à 4,5 kWh) sont en août 2008 et correspondent probablement à une absence du foyer ; les plus forts (jusqu'à 79,6 kWh) sont en hiver 2006-2007.
- **Saisonnalité.** De 34,5 kWh/jour en décembre-janvier à 12,7 kWh en août : le chauffage et l'éclairage pèsent en hiver, d'où la variable `mois`.
- **Week-end.** 28,8 kWh en moyenne contre 24,7 kWh en semaine (+17 %), d'où la variable `est_we`.
- **Retards.** Corrélation de la consommation avec celle de la veille 0,62, de J-7 0,55, de J-2 0,50, de J-14 0,47 : la veille et la semaine précédente sont les retards les plus informatifs.

Audit de fuite et variables construites

Nous excluons `Global_reactive_power`, `Voltage`, `Global_intensity` et les trois `Sub_metering` **du jour à prédire** : mesurés en même temps que la cible, ils ne sont pas connus la veille (`Global_intensity` est quasi proportionnelle à la puissance qui sert à calculer la cible). Variables construites : la consommation de la veille (`conso_J_minus_1`) et celle du même jour la semaine précédente (`conso_J_minus_7`), vérifiées par date, le jour de la semaine, le mois, le week-end, et en modélisation la moyenne des 7 jours précédents.

Axe 4 · Développement du modèle

Les données sont découpées dans l'ordre chronologique : 930 jours d'entraînement (29/12/2006 → 02/02/2010) et 233 jours de test (03/02/2010 → 25/11/2010), utilisé **une seule fois**. Toute la préparation (standardisation, encodage) est dans un `Pipeline` scikit-learn ajusté sur le train. Nous comparons trois baselines (« veille », « même jour la semaine dernière », « moyenne des 7 jours ») et trois modèles (régression linéaire, arbre, Random Forest) par validation croisée temporelle (`TimeSeriesSplit`, 5 plis), avec réglage de `max_depth`.

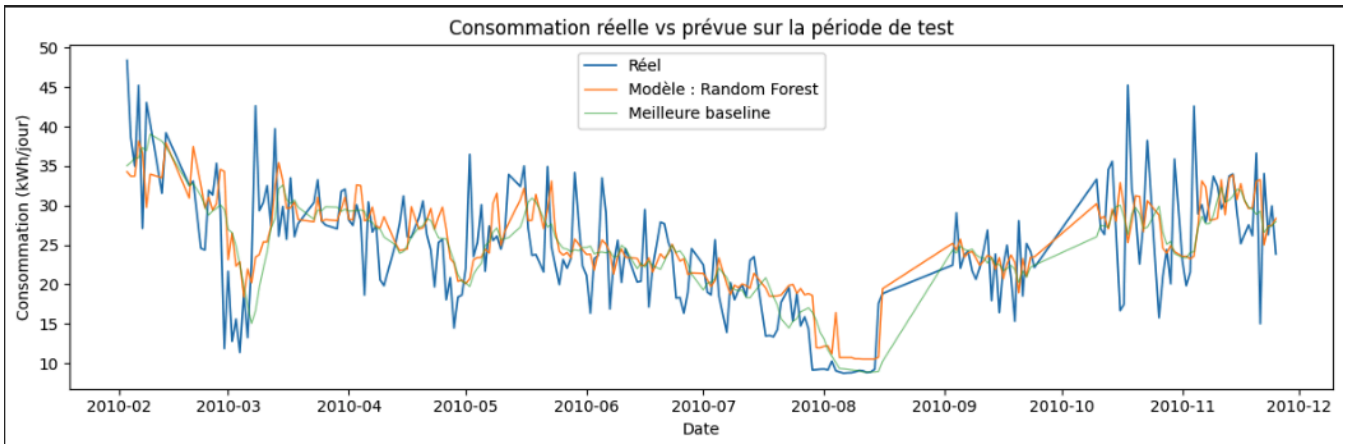
Modèle	MAE train (kWh)	MAE validation (kWh, moy. ± écart-type)
Baseline : moyenne 7 jours	6,59	5,06 ± 0,55
Random Forest (max_depth = 3)	5,27	5,20 ± 0,43
Arbre de décision (max_depth = 4)	4,92	5,68 ± 0,75
Régression linéaire	5,64	5,71 ± 2,02
Baseline : veille (situation actuelle)	7,58	6,02 ± 0,65
Baseline : même jour semaine précédente	8,06	6,26 ± 0,60

Lecture. Le Random Forest est le meilleur vrai modèle et il est retenu, mais il ne bat pas la moyenne des 7 jours en validation : l'écart (5,20 contre 5,06) est plus petit que l'écart-type, donc non fiable. Face à la veille, il gagne environ 14 %. L'arbre montre un léger surapprentissage (4,92 en train contre 5,68 en validation ; 6,60 à `max_depth = 8`) et la régression linéaire est instable (écart-type 2,0 kWh).

Résultats sur le test (données jamais vues)

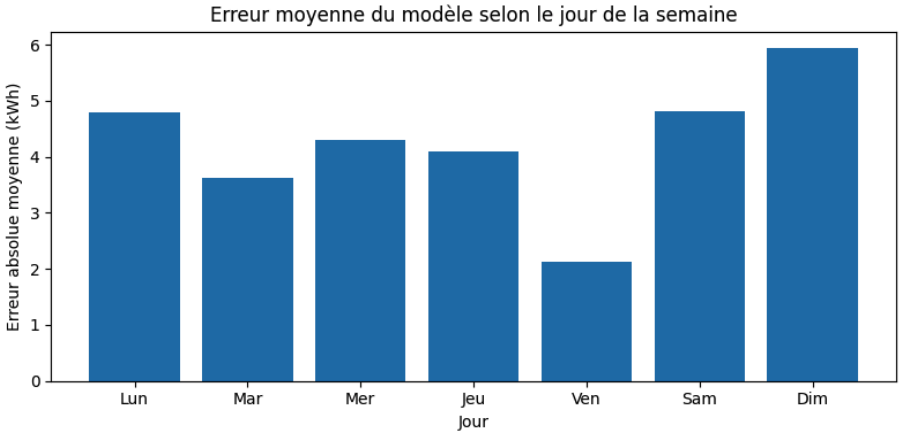
Référence	MAE (kWh)	RMSE (kWh)
Baseline « veille » (situation actuelle)	4,82	6,78
Baseline « moyenne 7 jours »	4,18	5,76
Random Forest (modèle retenu)	**4,19**	**5,71**

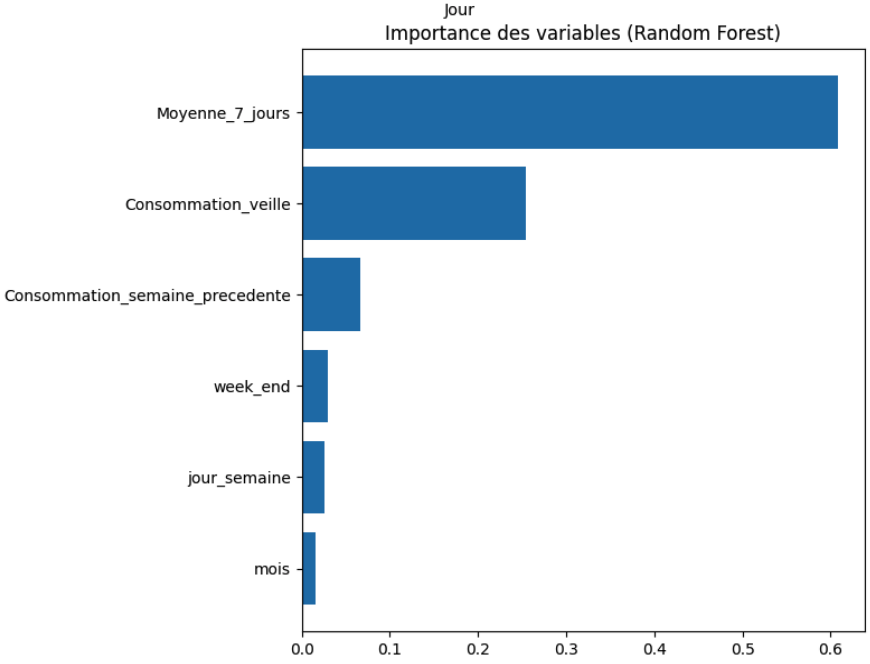
En moyenne, la prévision du lendemain se trompe de **4,19 kWh**, soit 17,3 % de la consommation moyenne du test (24,2 kWh/jour), contre 4,82 kWh pour la méthode actuelle : **−13,1 %** face à la veille, mais seulement −0,1 % face à la moyenne 7 jours.



Le modèle suit le niveau général et la saisonnalité (creux d'août autour de 9 kWh/jour) mais lisse les pics et les creux brusques : la chute de début mars 2010 et les jours très hauts d'octobre-novembre ne sont pas anticipés. Les segments droits en août-septembre correspondent à des jours manquants.

Erreurs et importance des variables





L'erreur est la plus forte le dimanche (environ 5,9 kWh) et la plus faible le vendredi (environ 2,1 kWh) : les week-ends dépendent de la présence des habitants, que le modèle ne connaît pas. Les plus grosses erreurs (13 à 22 kWh) tombent sur des jours de rupture : le 28/02/2010 (réel 11,9 kWh, prévu 34,3), le 18/10/2010 (réel 45,2, prévu 25,3), le 08/03/2010 (réel 42,6, prévu 23,5) ; plusieurs jours très bas début mars ressemblent à une absence du foyer (hypothèse à confirmer). La moyenne des 7 jours précédents domine (importance 0,61), devant la veille (0,25) ; la semaine précédente (0,07), le week-end (0,03), le jour (0,03) et le mois (0,02) pèsent peu. Cela explique pourquoi la meilleure baseline est elle-même une moyenne des jours précédents.

Axe 5 · Choix des métriques

Métrique principale : la MAE. Exprimée en kWh, elle est comprise par un décideur (« notre prévision se trompe en moyenne de X kWh par jour ») et peu sensible aux quelques jours atypiques (absences, pics isolés). Elle départage les modèles en validation croisée et sert à vérifier le critère de succès.

Garde-fou : le RMSE. Il pénalise davantage les grosses erreurs, les plus coûteuses pour un acheteur d'énergie. Sur le test, le RMSE du modèle (5,71 kWh) est inférieur de 15,8 % à celui de la veille (6,78) et de 0,9 % à celui de la moyenne 7 jours (5,76) : il limite un peu mieux les grosses erreurs, même si sa MAE est identique.

Écartées : le R^2, qui ne dit rien en kWh, et le MAPE, instable quand la consommation s'approche de zéro (creux d'août à environ 9 kWh).

Critère de succès. L'objectif de −20 % de MAE n'est **pas atteint** : −13,1 % face à la veille, −0,1 % face à la moyenne 7 jours. Le résultat est recevable : avec des retards et du calendrier sur un seul foyer, le modèle apporte un gain réel face à la méthode actuelle, mais pas face à une moyenne glissante.

Axe 6 · Justification métrique et business

Deux types d'erreur, qui ne coûtent pas pareil :

Erreur	Conséquence	Hypothèse de prix	Perte
Sous-estimation	Énergie manquante, rachetée en urgence	0,15 €/kWh au lieu de 0,10 €	0,05 €/kWh
Surestimation	Surplus revendu à perte	0,07 €/kWh au lieu de 0,10 €	0,03 €/kWh

Ces prix sont des **hypothèses de l'équipe**, à confirmer avec des prix de marché. Sur le test, le modèle sous-estime 40 % des jours (la veille : 53 %), soit un coût moyen d'environ 0,04 € par kWh d'erreur. En kWh, l'erreur moyenne de 4,19 kWh/jour représente 17 % de la consommation d'un foyer. En euros, le coût d'erreur par foyer et par an, calculé jour par jour sur le test, est d'environ **71 €** avec la méthode actuelle, **60 €** avec la moyenne 7 jours et **58 €** avec le modèle. Comme une sous-estimation coûte plus cher qu'une surestimation, une piste d'amélioration serait de décaler légèrement les prévisions vers le haut.

Axe 7 · ROI potentiel

Gain annuel = nombre de foyers × gain par foyer et par an ; ROI (%) = (gain annuel − coût du projet) / coût du projet × 100 ; délai de retour (mois) = coût du projet / (gain annuel / 12). Hypothèses : 10 000 foyers et un coût de projet de 50 000 € la première année (40 000 € de développement, 10 000 € d'exploitation : hébergement, suivi, réentraînement).

Face à la méthode actuelle, le gain est de 12,76 € par foyer et par an (71 € − 58 €). Scénario central : 10 000 × 12,76 € = 127 600 € ; ROI = (127 600 − 50 000) / 50 000 = 155,2 %.

Scénario	Hypothèse	Gain annuel	ROI an 1	Retour
Pessimiste	Amélioration et écarts de prix divisés par 2	31 900 €	−36,2 %	18,8 mois
Central	Résultat mesuré sur le test (−13,1 %)	127 600 €	155,2 %	4,7 mois
Optimiste	Objectif de −20 % atteint	194 600 €	289,1 %	3,1 mois
Référence = moyenne 7 jours	Gain de 2,16 € par foyer et par an	21 600 €	−56,7 %	27,7 mois

Sensibilité (une hypothèse à la fois, à partir du scénario central) :

Cas	Gain annuel	ROI an 1	Retour
Écarts de prix divisés par 2	63 800 €	27,6 %	9,4 mois
Portefeuille de 5 000 foyers	63 800 €	27,6 %	9,4 mois
Portefeuille de 1 000 foyers	12 800 €	−74,5 %	47,0 mois
Coût du projet doublé (100 000 €)	127 600 €	27,6 %	9,4 mois

[Insérer ici : graphiques « Gain annuel par scénario » et « Gain net selon la taille du portefeuille »]

Lecture. Face à la méthode actuelle, le projet est rentable dans les scénarios central et optimiste mais pas dans le pessimiste, et il faut environ 3 900 foyers pour atteindre l'équilibre. **Le résultat dépend fortement de la référence** : face à la moyenne des 7 derniers jours, que le modèle ne bat pas, le gain devient faible (ROI négatif, environ 23 000 foyers nécessaires). Les hypothèses les plus sensibles sont la taille du portefeuille, le niveau des prix et le coût du projet ; elles sont à valider en priorité. L'extrapolation d'un foyer à 10 000 foyers est probablement optimiste.

Axe 9 · Risques et enjeux

Les probabilités et impacts sont des estimations de l'équipe, à valider lors d'un pilote.

Catégorie	Risque	Probabilité	Impact	Mesure de réduction
Technique	**Un seul foyer** dans les données : le modèle ne se généralise pas (habitudes, taille, chauffage différents)	Élevée	Élevé	Pilote sur des foyers variés avant déploiement ; réentraînement par segment
Technique	**Données anciennes (2006-2010)** : habitudes et équipements ont changé	Élevée	Moyen	Réentraîner sur des données récentes ; suivre la MAE chaque mois
Technique	**Gain non démontré face à une moyenne simple** :	Élevée	Élevé	Prendre la moyenne 7 jours comme référence tant que

Catégorie	Risque	Probabilité	Impact	Mesure de réduction
	MAE 4,19 contre 4,18 kWh, écart inférieur à l'écart-type			le modèle ne la bat pas nettement ; ajouter météo et jours fériés
Technique	**Jours de rupture** (absence, retour de vacances) : erreurs de 13 à 22 kWh	Moyenne	Moyen	Alerte si l'erreur dépasse un seuil ; variable de présence si disponible
Technique	**Jeu de test court** (233 jours, une année)	Moyenne	Moyen	Évaluer sur plusieurs périodes (validation glissante)
Technique	**Capteur en panne / jours manquants** (1,25 % de mesures manquantes)	Moyenne	Moyen	Repli sur « même jour la semaine précédente » ; ne jamais calculer un retard sur un jour absent
Technique	**Dérive des données** (nouveaux appareils, tarifs)	Moyenne	Élevé	Suivi mensuel des distributions ; réentraînement trimestriel
Métier	**Coût réel d'une erreur différent** de nos hypothèses (pertes de 0,05 et 0,03 €/kWh) : le ROI en dépend	Moyenne	Élevé	Mesurer les coûts réels pendant un pilote de 3 mois ; garder le scénario pessimiste
Métier	**Extrapolation d'un foyer à un portefeuille**	Élevée	Élevé	Présenter le ROI comme une estimation ; valider sur plusieurs foyers
Métier	**Gain trop faible** si la référence est déjà une moyenne glissante	Moyenne	Élevé	Comparer le ROI aux deux références ; recommander un pilote
Métier	**Faible adoption** par le responsable de l'approvisionnement	Moyenne	Moyen	Modèle simple et explicable ; formation et retours d'expérience
Éthique	**Données personnelles (RGPD)** : la consommation fine révèle les habitudes de vie	Moyenne	Élevé	Agréger, pseudonymiser, limiter la conservation, recueillir le consentement
Éthique	**Biais** : modèle appris sur un foyer moins précis pour d'autres profils	Moyenne	Moyen	Mesurer l'erreur par profil ; réentraîner par segment

Catégorie	Risque	Probabilité	Impact	Mesure de réduction
Éthique	**Explicabilité et responsabilité** d'une mauvaise prévision	Faible	Moyen	Modèle interprétable, journal des prévisions, validation humaine des gros achats
Environnement	**Coût énergétique** de l'entraînement et de l'exploitation	Faible	Faible	Modèles légers (forêt de 200 arbres, quelques secondes) ; réentraînement trimestriel

Le risque de fuite de données est maîtrisé : variables connues la veille, découpage chronologique, test utilisé une seule fois.

Recommandation

Le modèle améliore de 13,1 % l'erreur de la méthode actuelle mais pas celle d'une moyenne glissante sur 7 jours, et les données ne concernent qu'un foyer. Nous recommandons un **pilote de 3 mois sur un petit portefeuille de foyers**, avec des variables enrichies (météo, jours fériés), pour mesurer le vrai coût d'un kWh d'erreur et la vraie amélioration face aux deux références avant tout déploiement.

Reproductibilité et déclaration

Dépôt Git : https://github.com/ncostasusana-cmd/prevision-consommation-electrique , notebooks `01_cadrage_eda`, `02_modelisation`, `03_decision_roi`, `requirements.txt`, `random_state` fixé. Usage de l'IA générative déclaré dans le README : Claude (Anthropic), utilisé comme assistant de code et de rédaction.